

Análisis de Caso: Fallo en Sistema Distribuido Real

Amazon Web Services — us-east-1 (Abril 2011)

Integrantes: Cando M. Robinson R. • Luna M. Ernesto G. • Pacheco C. Cristhian D.

Universidad Técnica Estatal de Quevedo — Mayo 2026

I. DESCRIPCIÓN DEL INCIDENTE

El 21 de abril de 2011, a las 00:47 PDT (07:47 UTC), un cambio de red ejecutado incorrectamente enrutó el tráfico de la red primaria hacia la red de replicación de menor capacidad en us-east-1. Esto desconectó simultáneamente miles de nodos EBS de sus réplicas, desencadenando un proceso masivo de *re-mirroring* que agotó la capacidad del clúster. La demanda simultánea generó una retroalimentación positiva denominada *re-mirroring storm*: cada intento de recuperación empeoraba el estado del sistema, dejando volúmenes en estado *stuck* sin poder completar lecturas ni escrituras. Una *race condition* latente en el código de nodos EBS agravó la situación, y el plano de control EBS afectó las APIs de toda la región en dos periodos separados. La recuperación completa tomó aproximadamente 96 horas [1].

II. IDENTIFICACIÓN DE CAUSAS RAÍZ (ISHIKAWA)

La Figura 1 organiza las causas en cuatro categorías, verificadas contra el informe oficial [1].




Figura 1: Diagrama de Ishikawa: fallo AWS us-east-1 (Abril 2011).

Gestión del Cambio: tráfico enrutado erróneamente a la red de alta latencia; configuración incorrecta sin validación previa; ausencia de barreras automáticas de verificación.

Infraestructura y Red: la red de replicación no soportaba el volumen de tráfico de la red primaria; capacidad libre del clúster insuficiente; operaciones simultáneas a escala no prevista.

Automatización y Recuperación: miles de volúmenes iniciaron re-replicación simultánea; cada recuperación generaba más carga y nuevas pérdidas de réplica; los recursos críticos se agotaron.

Gestión de Resiliencia: los nodos seguían buscando espacio aunque no había disponible; un error de programación hizo fallar más nodos durante la crisis; un fallo en una zona afectó el control de toda la región [3].

III. IMPACTO CUANTIFICADO

- **Duración:** ≈ 96 h (21–24 de abril de 2011).
- **Volúmenes EBS:** pico de **13 %** bloqueados; 5 % adicionales por *race condition*; **0.07 %** irrecuperables.
- **RDS single-AZ:** pico de **45 %** afectadas; **0.4 %** con almacenamiento irrecuperable.
- **RDS multi-AZ:** **2.5 %** sin *failover* automático por bug no detectado previamente.
- **Cascada regional:** APIs degradadas en *todas* las zonas en dos ventanas: 00:47–02:50 y 05:30–08:20 PDT del 21 de abril [1].
- **Compensación:** crédito del **100 %** por 10 días para todos los clientes de la zona afectada.

IV. ESTRATEGIAS DE MITIGACIÓN APLICADAS

A. Contención

AWS detuvo la creación de nuevos volúmenes en la zona afectada y la aisló del resto de la región para evitar que el fallo se propagara [1].

B. Recuperación

Se añadió capacidad de servidores al clúster dañado y se restauraron los volúmenes afectados desde copias de respaldo. El 0.07 % de los volúmenes no pudo recuperarse [1].

C. Mejoras preventivas

Se corrigió el error de programación, se aumentó la capacidad de reserva y se mejoró el aislamiento entre zonas para que un fallo local no afecte a toda la región [1].

V. LECCIONES APRENDIDAS

Validación de cambios: Un cambio sin revisión automatizada puede desencadenar fallos regionales; todo cambio debe usar despliegue gradual (*canary*) [2].

Teorema CAP: El sistema priorizó consistencia sobre disponibilidad; esta decisión debe ser explícita y documentada según el contexto del servicio [2].

Retroalimentación positiva: Los mecanismos de recuperación deben incluir *rate limiting* y *backoff* para evitar que amplifiquen el fallo [3].

Aislamiento entre zonas: El plano de control compartido propagó el fallo; los componentes degradados no deben comprometer zonas independientes [3].

Capacidad de reserva: La ausencia de espacio libre convirtió un fallo contenible en una tormenta; todo sistema debe mantener al menos un **30 %** de capacidad libre.

Comunicación de incidentes: AWS reconoció demoras en notificar a clientes; el protocolo debe activarse al confirmar el primer impacto, con actualizaciones periódicas aunque la causa raíz sea desconocida.

REFERENCIAS

- [1] Amazon Web Services, “Summary of the Amazon EC2 and Amazon RDS Service Disruption in the US East Region,” *AWS Service Health Dashboard*, Apr. 2011. [Online]. Available: <https://aws.amazon.com/message/65648/>
- [2] E. Brewer, “Towards robust distributed systems,” in *Proc. 19th ACM Symp. Principles Distributed Computing (PODC)*, Portland, OR, USA, Jul. 2000, p. 7. doi: 10.1145/343477.343502
- [3] F. Cristian, “Understanding fault-tolerant distributed systems,” *Commun. ACM*, vol. 34, no. 2, pp. 56–78, Feb. 1991. doi: 10.1145/102792.102801

ANEXO

Repositorio: <https://github.com/CristhianP03/guia01-socketsv01.git>