
UNIVERSIDAD TÉCNICA ESTATAL DE QUEVEDO

Facultad de Ciencias de la Computación

Carrera de Ingeniería de Software

INSTRUMENTO DE EVALUACIÓN

GUÍA DE PRÁCTICA EXPERIMENTAL Y RÚBRICA DE EVALUACIÓN

GA-SUM-05 / PE-U4 – Práctica Experimental Unidad 4

Procesamiento Distribuido con Apache Spark: comprobación experimental de la Ley de Amdahl aplicada al Proyecto Fin de Curso

Asignatura:	Aplicaciones Distribuidas (ISR-701)
Unidad:	Unidad 4 – Cómputo Paralelo y Distribuido
Modalidad:	Grupal (equipos de 3–4 integrantes)
Carácter:	Sumativa
Calificación:	0–100 puntos
Semana de entrega:	Semana 14
Duración:	9 horas (3 h laboratorio + 6 h autónomas)
Período académico:	2026–2027 PPA
Docente responsable:	Gleiston C. Guerrero-Ulloa, M.Sc.

Piso de evaluación (no negociable)

La ausencia de cualquier indicador o criterio establecido en la rúbrica se califica con CERO (0) en ese criterio, sin excepciones. La calificación es siempre definitiva y se emite sobre la evidencia disponible al momento del cierre de la entrega. No se aceptan entregas parciales, provisionales ni ampliaciones fuera del plazo publicado en el LMS (SGA). Adicionalmente, el incumplimiento de cualquiera de los cinco pisos absolutos descritos en la sección 10.2 implica **nota final CERO** para todo el equipo, con independencia del trabajo realizado. En todos los casos se reporta al estudiante la *nota previa* (antes de pisos y penalizaciones) junto a la *nota final*, para que sea visible el valor del trabajo perdido.

PARTE A – GUÍA DE LA PRÁCTICA EXPERIMENTAL

1 Datos generales de la práctica

La presente guía conserva íntegramente la estructura y los contenidos del formato institucional de guías de práctica experimental de la UTEQ, y añade sobre ellos el instrumento de calificación (Parte B) y las precisiones de verificación necesarias para una evaluación sumativa trazable.

Código de actividad	GA-SUM-05 / PE-U4
Carrera	Software (Rediseño)
Asignatura	Aplicaciones Distribuidas (ISR-701) [20701]
Unidad	Unidad 4 – Cómputo Paralelo y Distribuido
Nivel / Paralelo	Séptimo nivel – Paralelo A
Profesor	Guerrero Ulloa Gleiston Cicerón, M.Sc.
Tipo de guía	Práctica experimental
Tipo de aprendizaje	Comprobación (verificación experimental de una ley)
Modalidad	Grupal (equipos de 3–4 integrantes)
Carácter	Sumativa
Semana de entrega	Semana 14
Tipo de ubicación	Interna
Tipo aula / laboratorio	Laboratorios
Aula / laboratorio	FCC-LAB-TIC-201
Ubicación	Campus Central
Número de horas	9 horas (3 h laboratorio + 6 h autónomas)
Período académico	2026–2027 PPA
Entregables	Notebook ejecutado (Colab o Databricks) + repositorio GitHub + documento L ^A T _E X (.tex y .pdf) + evidencia de ejecución

2 Resultados de aprendizaje

Resultado de aprendizaje principal de la unidad. Implementa soluciones de computación paralela y distribuida empleando tecnologías de procesamiento concurrente y plataformas de computación en la nube, evaluando su rendimiento e impacto.

Resultado de aprendizaje complementario de la asignatura. Construye aplicaciones distribuidas en capas que cumplan con estándares de calidad de software (ISO/IEC 25010), integrando mecanismos de seguridad y observando la ética del Ingeniero de Software.

El segundo resultado se ejercita en esta práctica de forma instrumental: la calidad del documento, la reproducibilidad del experimento, la trazabilidad de las mediciones y la declaración honesta del uso de herramientas de inteligencia artificial generativa constituyen evidencias directas de las características de calidad y de la conducta ética exigidas.

3 Tema y contexto de la práctica

Comprobación experimental de la Ley de Amdahl mediante la implementación y medición de un *pipeline* de procesamiento de datos en Apache Spark (PySpark) con cinco transformaciones, la comparación con el procesamiento secuencial equivalente en pandas, y el análisis cuantitativo del *speedup* obtenido frente al *speedup* teórico máximo predicho por el modelo de Amdahl [2] y por su reformulación de escalado de Gustafson [8].

La práctica cierra el recorrido conceptual de la Unidad 4 conectando cuatro capas: el modelo teórico de límites de paralelización, el paradigma MapReduce que popularizó el procesamiento por lotes a

gran escala [7], el motor unificado Apache Spark que lo superó para cargas iterativas mediante el modelo RDD en memoria [11], [12], y las plataformas de nube sobre las que hoy se ejecutan estos motores [9].

3.1 Selección obligatoria del PFC de referencia

Los equipos que rinden esta práctica se conforman de forma independiente de los equipos que desarrollan los PFC del período; en consecuencia, sus integrantes pueden pertenecer a distintos PFC. Es obligatorio que el equipo, en consenso, elija uno y solo uno de los cuatro PFC del período como dominio de referencia para toda la práctica, y que declare explícitamente esa elección en la portada del entregable.

Dominios PFC vigentes en el período 2026–2027 PPA (elegir uno)

- **AGLS – TiendaTech:** plataforma de comercio electrónico de hardware con asistente de compatibilidad.
- **BCEL – SGA Escuela Provincias Unidas:** sistema de gestión académica.
- **FUVV – Laboratorios Informáticos:** reserva y monitoreo distribuido de laboratorios.
- **ACC – Soporte Técnico ISP:** gestión de tickets de soporte técnico.

La portada del entregable debe consignar: (a) código del PFC elegido; (b) título del sistema; (c) integrantes del equipo con su PFC de origen y el rol asumido; y (d) justificación técnica (mínimo 100 palabras) que explique por qué el dominio elegido genera volúmenes de datos que justifican un motor distribuido y qué decisión de negocio se apoyaría en el *pipeline* implementado.

4 Objetivos de la práctica

Objetivo general. Comprobar experimentalmente la Ley de Amdahl implementando y midiendo el rendimiento de un *pipeline* distribuido de datos con Apache Spark sobre un conjunto de datos real de al menos 500 000 registros, comparándolo con el procesamiento secuencial equivalente.

Objetivos específicos.

1. Implementar las mismas cinco transformaciones con pandas (secuencial) y con PySpark (distribuido).
2. Medir los tiempos de ejecución con precisión de microsegundos, con cinco repeticiones por transformación y reporte de la mediana.
3. Calcular el *speedup* experimental y compararlo con el *speedup* teórico de Amdahl.
4. Determinar la fracción serial de cada transformación y el límite práctico de paralelización.

Sobre los mínimos de la consigna breve publicada en el LMS

La consigna resumida publicada en el aula virtual fija como piso de admisibilidad un conjunto de datos de al menos 100 000 registros y tres transformaciones (filtrado y selección, agrupación y agregación, y *join* de al menos dos *DataFrames*). Esta guía **no reduce** ese piso: lo eleva y lo detalla, exigiendo 500 000 registros y cinco transformaciones (T1–T5), de las cuales las tres de la consigna breve corresponden a T1, T2 y T3. Los mínimos de la consigna breve se consideran, por tanto, la condición de admisibilidad; los de esta guía, la condición de suficiencia para aspirar a los niveles 3 y 4 de la rúbrica.

5 Fundamento teórico requerido

Requisito bibliográfico obligatorio

El fundamento teórico se redacta en $\text{\LaTeX}$, con un mínimo de 300 palabras por subtema. Cada afirmación no trivial (definición, propiedad, ley, comparación, cifra o afirmación de rendimiento) debe estar respaldada por al menos DOS referencias académicas de alto impacto con DOI o ISBN verificable. Las ecuaciones de Amdahl y de Gustafson-Barsis **deben** presentarse en entornos `equation` o `align` numerados y ser referenciadas desde el texto con `\eqref`. Los gráficos deben generarse con `matplotlib` e incluirse con `\includegraphics`; no se admiten capturas de pantalla de gráficos. El uso de blogs, wikis o sitios comerciales como fuente principal se penaliza en el criterio 4.3.

5.1 Fundamentos de paralelismo y Ley de Amdahl

Desarrollar: paralelismo de datos y paralelismo de tareas; Ley de Amdahl (1967) con derivación matemática completa; *speedup* teórico máximo; eficiencia del paralelismo; Ley de Gustafson-Barsis como alternativa de escalado; y representación gráfica del *speedup* frente al número de procesadores para fracciones paralelizables $p = 0,5, 0,75, 0,9$ y $0,95$. Referencias mínimas: [2], [8].

Formalización mínima exigida

Sea p la fracción paralelizable de una tarea, $(1 - p)$ su fracción estrictamente serial y N el número de unidades de procesamiento. El *speedup* de Amdahl es

$$S(N) = \frac{1}{(1 - p) + \frac{p}{N}}, \quad (1)$$

cuyo límite superior, cuando $N \rightarrow \infty$, queda fijado exclusivamente por la fracción serial:

$$S_{\text{máx}} = \lim_{N \rightarrow \infty} S(N) = \frac{1}{1 - p}. \quad (2)$$

La reformulación de escalado de Gustafson-Barsis, que supone carga de trabajo creciente con los recursos, es

$$S_G(N) = N - (1 - p)(N - 1). \quad (3)$$

Despejando p de (1) se obtiene la fracción serial implícita en una medición experimental con N unidades y *speedup* observado S (métrica de Karp-Flatt en su forma equivalente):

$$p = \frac{\frac{1}{S} - \frac{1}{N}}{1 - \frac{1}{N}}, \quad N > 1. \quad (4)$$

Finalmente, la eficiencia del paralelismo se define como

$$E(N) = \frac{S(N)}{N}. \quad (5)$$

Advertencia metodológica: la magnitud despejada mediante (4) no es la fracción serial *algorítmica*, sino la fracción no escalable *observada*, que agrega la sobrecarga de planificación, serialización y *shuffle* del motor. Confundir ambas es un error conceptual penalizado en el criterio 2.2.

5.2 Paradigma MapReduce y Apache Hadoop

Desarrollar: modelo MapReduce de Dean y Ghemawat; descripción formal de las funciones *Map* y *Reduce*; flujo completo de ejecución (*split*, *map*, *shuffle*, *sort*, *reduce*); arquitectura Hadoop (HDFS y YARN); ventajas sobre el procesamiento tradicional; y limitaciones para el procesamiento iterativo. Referencias mínimas: [7], [10]. Toda afirmación comparativa de rendimiento entre Hadoop y Spark debe citar evidencia empírica publicada, por ejemplo un estudio de *benchmarking* sistemático [1], y no material promocional de proveedores.

5.3 Apache Spark: arquitectura y modelo de programación

Desarrollar: arquitectura de Spark (*driver*, *cluster manager*, *executors*); modelo RDD y su *lineage* para tolerancia a fallos; API de *DataFrames* y *Datasets*; evaluación perezosa frente a acciones; modelo de ejecución (DAG, *stages*, *tasks*); y comparación de rendimiento de Spark frente a MapReduce. Referencias mínimas: [6], [11]. Se recomienda complementar con la síntesis del motor unificado [12] y con la descripción del optimizador Catalyst y de la API relacional [3], ya que ambos son necesarios para explicar por qué las transformaciones sobre *DataFrames* no se ejecutan en el orden en que se escriben.

5.4 Computación en la nube: modelos y proveedores

Desarrollar: modelos de servicio en la nube (IaaS, PaaS, SaaS, FaaS) con la definición del NIST; características esenciales del cómputo en la nube; comparación de AWS, Azure y GCP para procesamiento distribuido (EMR, HDInsight y Dataproc); y arquitecturas Lambda y Kappa. Referencias mínimas: [5], [9]. Las afirmaciones sobre costo o dimensionamiento de recursos deben apoyarse en literatura arbitrada sobre recomendación de recursos para flujos de trabajo basados en DAG [4] o en documentación oficial del proveedor con fecha de consulta.

6 Materiales, equipos, insumos y reactivos

6.1 Plataformas de cómputo

- Google Colab (<https://colab.research.google.com>) — gratuito, 12 GB de RAM, GPU opcional. Recomendado.
- Databricks Community Edition (<https://community.cloud.databricks.com>) — gratuito, Spark preinstalado.
- Instalación local: Python 3.10+, Apache Spark 3.5.0 y Java 11+ (requisito de Spark).

6.2 Software y librerías

- PySpark 3.5.0: `pip install pyspark==3.5.0`.
- pandas 2.x, matplotlib 3.x, numpy 1.x (estándar de Python para medición y graficación).
- Kaggle API (opcional): `pip install kaggle` para la descarga reproducible de conjuntos de datos.
- L^AT_EX con los paquetes `listings`, `booktabs`, `graphicx`, `amsmath` y `siunitx` (unidades de tiempo).
- Gestión bibliográfica con `biblatex` estilo IEEE y `biber`.
- Git 2.x y cuenta institucional en GitHub.

6.3 Equipos

- Computadora con memoria RAM igual o superior a 16 GB (si se ejecuta Spark localmente).

- Si se trabaja en Colab o Databricks, basta un equipo capaz de sostener una sesión de navegador estable.

6.4 Insumos

- Conexión a Internet con ancho de banda superior a 2 MBps.
- Conjunto de datos público con licencia de uso explícita y URL permanente.

7 Procedimiento

Los pesos indicados entre paréntesis corresponden a la porción de la rúbrica (Parte B) que se decide en cada paso.

Paso 1 — Preparación del entorno y del conjunto de datos (peso 7 %)

Acceder a Google Colab o a Databricks Community Edition; en Colab, instalar con `!pip install pyspark==3.5.0`. Descargar un conjunto de datos real de al menos 500 000 registros, relacionado con el dominio del PFC elegido, desde una fuente pública verificable: Kaggle, INEC Ecuador (<https://www.ecuadorencifras.gob.ec>), <https://www.datosabiertos.gob.ec>, portales de datos abiertos equivalentes u otro repositorio con URL permanente. Si, y solo si, no existe un conjunto real adecuado para el dominio, se admite la generación sintética con **Faker**, siempre que se declare explícitamente como sintética, se publique el *script* generador con semilla fija y se justifique la decisión; presentar datos sintéticos como reales se sanciona como falta de integridad académica. Documentar en una tabla **booktabs**: fuente, URL, licencia, fecha de descarga, número de registros, número de columnas y tamaño en disco. Cargar el conjunto en pandas y en un *DataFrame* de PySpark, y verificar en ambos el número de registros y el esquema inferido.

Paso 2 — Implementación secuencial con pandas (peso 6 %)

Implementar cinco transformaciones con pandas, sin paralelismo:

- **T1**: filtrado por condición compuesta y selección de columnas.
- **T2**: agrupación (*groupby*) con agregación de al menos tres funciones.
- **T3**: *join* de al menos dos *DataFrames*.
- **T4**: columna derivada compleja (expresión sobre varias columnas o función definida por el usuario).
- **T5**: ordenamiento y selección de los n primeros registros (*top-N*).

Medir cada transformación con `time.perf_counter()`: cinco repeticiones y cálculo de la mediana. Guardar el resultado de cada transformación en formato CSV dentro de `data/pandas/`.

Advertencia metodológica

Ejecutar cada transformación de manera independiente, en celdas separadas y sin reutilizar resultados intermedios de la transformación anterior, para que los tiempos individuales sean comparables. Descartar de forma explícita la primera ejecución de calentamiento cuando se documente el criterio de medición.

Paso 3 — Implementación distribuida con PySpark (peso 8 %)

Inicializar la sesión con `SparkSession.builder.config('spark.executor.instances', '4').getOrCreate()` y documentar la configuración efectiva obtenida con `spark.sparkContext.getConf().getAll()`. Implementar las mismas cinco transformaciones con *DataFrames* de PySpark; los resultados deben ser idénticos a los de pandas. Medir los tiempos con el mismo

protocolo (cinco ejecuciones, mediana), forzando la materialización con una acción (por ejemplo `count()` o escritura a disco) para no medir únicamente la construcción perezosa del DAG. Para T3 (*join*), medir con 1, 2 y 4 *executors* a fin de habilitar el análisis de escalabilidad. Verificar la equivalencia de resultados entre pandas y PySpark para cada transformación mediante comparación de cardinalidad y de agregados de control (sumas, promedios y conteos por clave).

Evidencia de ejecución obligatoria

El notebook entregado debe conservar las salidas de todas las celdas (no se admiten notebooks con celdas sin ejecutar). Es obligatorio incluir en el documento al menos una captura de la interfaz de Spark (*Spark UI*) que muestre el DAG y los *stages* del *job* correspondiente a T3, como figura con `\caption`, `\label` y referencia cruzada en el texto. Se recomienda, sin ser obligatorio, grabar un video de pantalla de 2 a 5 minutos con la ejecución completa y enlazarlo en el `README.md`.

Paso 4 — Análisis cuantitativo: Ley de Amdahl (peso 18 %)

Para cada transformación, calcular el *speedup* como $S = T_{\text{pandas}}/T_{\text{spark}}$. Para T3 con 1, 2 y 4 *executors*, calcular la fracción serial observada p mediante la forma inversa (4). Calcular el *speedup* teórico máximo predicho por Amdahl para $N \rightarrow \infty$ con el valor de p obtenido, aplicando (2). Generar con `matplotlib` y exportar en PNG a 300 DPI:

- gráfico de barras con los tiempos de pandas frente a PySpark por transformación;
- curva de *speedup* frente a N con la curva de Amdahl superpuesta;
- curva de eficiencia $E = S/N$ frente a N , según (5).

Núcleo del análisis

La comparación entre la curva teórica y el *speedup* real es el núcleo de esta práctica y debe documentarse con ecuaciones $\text{\LaTeX}$ numeradas y con el trabajo matemático explícito, no solo con el resultado final. Un informe que presente los gráficos sin la sustitución numérica paso a paso no supera el nivel 2 en el criterio 2.2.

Paso 5 — Documento $\text{\LaTeX}$ y entregables (peso 61 % distribuido en D2–D6)

Redactar y compilar el documento en $\text{\LaTeX}$ cumpliendo los siguientes requisitos verificables:

- Estructura de artículo técnico: portada institucional, resumen, introducción, fundamento teórico, procedimiento aplicado, resultados, análisis crítico, conclusiones individuales y bibliografía.
- Extensión mínima de 14 páginas de contenido, sin contar portada, índice ni bibliografía.
- Fundamento teórico completo de la Unidad 4 con las ecuaciones de Amdahl y Gustafson en entornos `equation` o `align` numerados.
- Código PySpark y pandas en `lstlisting` con `caption` y `label`.
- Tabla `booktabs` de tiempos medidos, con unidades expresadas mediante `siunitx`.
- Las tres figuras de `matplotlib` con `\caption`, `\label` y análisis interpretativo propio de cada una.
- Cálculo del *speedup* con trabajo matemático explícito.
- Respuestas a las cuatro preguntas del Anexo A.
- Conclusiones individuales por integrante.
- Bibliografía gestionada con `biblatex` estilo IEEE y al menos 8 referencias verificadas, de las cuales al menos 6 con DOI o ISBN.

- Compilación limpia con `pdflatex`; las advertencias de *overfull hbox* son penalizables.
- Declaración obligatoria de uso de inteligencia artificial generativa al final del documento (herramienta, propósito y secciones asistidas).

8 Entregables y forma de entrega

En el LMS (SGA) los estudiantes suben únicamente el documento breve de identificación con la URL del repositorio: no se suben archivos ZIP, notebooks ni informes. Todo el resto del trabajo reside en el repositorio.

Contenido del envío al LMS (documento único de UNA página)

El equipo sube al LMS un archivo PDF de exactamente una página, nombrado `PE-U4_[CodigoEquipo]_[PFC].pdf`, que contiene solo la carátula de identificación y la URL del repositorio:

- Datos de identificación: universidad, facultad, carrera, asignatura, código de actividad, período y docente.
- Código del equipo, integrantes con su PFC de origen y rol asumido.
- Código y título del PFC de referencia elegido.
- **URL del repositorio público de GitHub en una sola línea, íntegra y no fraccionada.** Se recomienda un nombre corto de repositorio, por ejemplo `pe-u4-spark-{equipo}`.
- Declaración de uso de inteligencia artificial generativa (herramienta, propósito y secciones asistidas).

Si la URL está rota, aparece partida en más de una línea, el repositorio no es accesible o el PDF excede una página, la calificación del equipo es CERO.

Estructura mínima obligatoria del repositorio:

```

1 pe-u4-spark-[equipo]/
2 |-- README.md                (descripcion, integrantes, PFC de referencia,
3 |                            instrucciones EXACTAS de compilacion LaTeX)
4 |-- LICENSE
5 |-- notebooks/
6 |   |-- PE_U4_pipeline_spark.ipynb (notebook EJECUTADO, con salidas visibles)
7 |   '-- PE_U4_pipeline_spark.html (exportacion HTML del notebook ejecutado)
8 |-- src/
9 |   |-- transformaciones_pandas.py (T1..T5 secuenciales)
10 |   |-- transformaciones_spark.py  (T1..T5 distribuidas)
11 |   |-- medicion.py                (5 repeticiones, mediana, perf_counter)
12 |   '-- graficas.py                (3 figuras matplotlib a 300 DPI)
13 |-- data/
14 |   |-- README_dataset.md          (fuente, URL, licencia, fecha, num. registros)
15 |   |-- pandas/                    (CSV de salida de cada transformacion)
16 |   '-- spark/                     (CSV de salida de cada transformacion)
17 |-- resultados/
18 |   |-- tiempos_crudos.csv          (5 repeticiones por transformacion)
19 |   |-- tiempos_resumen.csv         (medianas y speedups)
20 |   '-- figuras/                   (fig1_barras.png, fig2_speedup.png,
21 |                                   fig3_eficiencia.png)
22 |-- evidencia/
23 |   '-- spark_ui_t3.png             (captura del DAG y stages de T3)
24 '-- docs/
25 |   |-- PE_U4_Informe.tex           (documento LaTeX fuente)
26 |   |-- PE_U4_Informe.pdf           (documento compilado)
27 |   '-- references_U4.bib           (bibliografia biblatex)

```

Listing 1: Estructura del repositorio de entrega

Repositorio inaccesible o documento no reproducible $\Rightarrow$ nota CERO

El repositorio es el único canal por el que el trabajo llega al docente: todos los entregables (notebook, código, datos, resultados, figuras, documento y evidencia) residen allí. Si el docente no puede acceder (repositorio inexistente, privado sin permiso concedido, URL rota o mal transcrita), no hay evidencia que evaluar y la calificación final del equipo es CERO. Del mismo modo, si el PDF del informe no se genera correctamente a partir del `.tex` mediante clonación del repositorio y compilación, la calificación final es CERO; las instrucciones de compilación (compilador, orden de comandos, archivo principal y dependencias) deben estar documentadas en el `README.md`. El equipo debe verificar antes del cierre que la URL abre correctamente en modo anónimo y que la secuencia documentada reproduce el PDF en una máquina limpia.

9 Anexo A — Preguntas de análisis obligatorias

Las siguientes cuatro preguntas deben responderse en el documento L^AT_EX, en una sección específica denominada “Preguntas de análisis”, con al menos 200 palabras cada una y citando referencias del archivo `.bib`:

1. Calcule el *speedup* teórico máximo ($N \rightarrow \infty$) para la transformación T3 con el valor de p que obtuvo. ¿Con cuántos procesadores se alcanza el 90 % del *speedup* máximo? Muestre el trabajo matemático completo.
2. ¿Por qué algunas transformaciones muestran *speedup* menor que 1, es decir, PySpark más lento que pandas? ¿Cuál es el costo de sobrecarga (*overhead*) de Spark y qué tamaño mínimo de conjunto de datos justifica su uso en el dominio del PFC elegido?
3. ¿Cómo implementaría el *pipeline* del PFC con Spark Structured Streaming si los datos llegaran en tiempo real? Describa la arquitectura, indicando fuentes, *sinks*, política de *triggers* y garantías de entrega.
4. ¿Por qué Spark es más eficiente que MapReduce para el procesamiento iterativo? Justifique con los conceptos de *lineage* de los RDD y de evaluación perezosa.

PARTE B – RÚBRICA DE EVALUACIÓN

10 Marco de evaluación

Esta rúbrica evalúa la Práctica Experimental de la Unidad 4 con carácter sumativo y grupal. La calificación se emite sobre 100 puntos a partir de seis dimensiones y veinte criterios. Cada criterio se valora en cinco niveles: Sobresaliente (4), Satisfactorio (3), En desarrollo (2), Insuficiente (1) y Ausente (0). Los puntos obtenidos por criterio se calculan como $\text{Nivel} \times (\text{Peso}/4)$, con el peso expresado en porcentaje sobre 100.

10.1 Escala de calificación

Nivel	Descripción general	Equivalencia
4 – Sobresaliente	Cumple todos los requisitos con calidad académica publicable: experimento completo y verificable, análisis cuantitativo riguroso, documento impecable.	90–100 / 100
3 – Satisfactorio	Cumple los requisitos con calidad académica sólida; deficiencias menores en el análisis, la documentación o la profundidad.	75–89 / 100
2 – En desarrollo	Cumple parcialmente; requiere mejoras sustanciales en implementación, medición, análisis o documentación.	60–74 / 100
1 – Insuficiente	No alcanza los estándares mínimos: experimento incompleto o documento deficiente.	40–59 / 100
0 – Ausente	No entregado, plagio verificado, datos fabricados, o el criterio no se desarrolla.	< 40 / 100

10.2 Pisos absolutos y condiciones obligatorias de aprobación

Condición	Verificación que realiza el docente	Efecto
P1. Documento LMS de una página con URL en una sola línea	Se abre el PDF subido al SGA: debe tener exactamente una página, contener la carátula de identificación y mostrar la URL íntegra en un solo renglón.	Nota final = 0
P2. PDF reproducible desde el .tex	Se clona el repositorio y se ejecuta la secuencia documentada en el README.md (<code>pdflatex → biber → pdflatex → pdflatex</code>).	Nota final = 0
P3. Repositorio accesible	<code>GIT_TERMINAL_PROMPT=0 git ls-remote <url> HEAD</code> en modo anónimo.	Nota final = 0
P4. Integridad de los datos y del texto	Contraste de resultados del notebook con los reportados; verificación de similitud; comprobación de que las mediciones proceden de una ejecución real.	Nota final = 0
P5. Presencia de los indicadores	Todo indicador o criterio ausente se califica con 0 en ese criterio, sin negociación.	Criterio = 0
Notebook con salidas	El .ipynb conserva las salidas de todas las celdas.	Si no: 1.3 = 0
Volumen y procedencia del conjunto de datos	<code>count()</code> sobre el <i>DataFrame</i> y verificación de la URL de la fuente.	Si < 500 000 registros o fuente no verificable: 1.1 = 0
Declaración del PFC de referencia	La portada indica el PFC elegido y su justificación.	Si no se declara: 1.1 = 0
Escalado con varios <i>executors</i>	Existen mediciones de T3 con 1, 2 y 4 <i>executors</i> .	Si faltan: 2.1 nivel máximo 1
Formato de referencias	Se revisa el estilo aplicado en la bibliografía.	APA en lugar de IEEE: 4.3 = 0
Extensión del informe	Recuento de páginas de contenido.	< 14 páginas: nivel máximo 2 en D4

10.3 Penalizaciones específicas

- Ausencia de la declaración de uso de inteligencia artificial generativa: -3 puntos sobre el total.
- Cada DOI inválido o mal asignado (que resuelve a una obra distinta de la citada): $-0,5$ puntos, hasta un máximo de -5 puntos.
- Conjunto de datos sintético presentado como real, o sin declaración de licencia y fuente: -10 puntos y anotación de integridad académica.
- Referencias de editoriales depredadoras (por ejemplo EJCSIT/EAJournals): nivel máximo 1 en el criterio 4.3 y anotación de integridad académica.
- Uso de formato APA en lugar de IEEE en las referencias: criterio 4.3 = 0. No se admite un formato distinto de IEEE porque así lo exige la asignatura de forma explícita.
- Advertencias de *overfull hbox* en la compilación: descuento dentro del criterio 4.1, sin exceder un nivel.

11 Matriz de dimensiones y criterios

Criterio	Peso	4 – Sobresaliente	3 – Satisfactorio	2 – En desarrollo	1 – Insuficiente
D1 – ENTORNO, CONJUNTO DE DATOS E IMPLEMENTACIÓN DEL PIPELINE (25 %)					
1.1 Entorno Spark y conjunto de datos real	7 %	Conjunto real con más de 500 000 registros de fuente pública verificable, con URL permanente, licencia y fecha documentadas en tabla <i>booktabs</i> ; PFC de referencia declarado y justificado con más de 100 palabras; configuración de la sesión Spark documentada.	Conjunto real con al menos 500 000 registros y fuente verificable; documentación de licencia o justificación del PFC breve.	Conjunto entre 100 000 y 500 000 registros, o fuente citada sin licencia ni fecha.	Conjunto menor al mínimo admisible o de procedencia no rastreable.
1.2 Implementación secuencial con pandas	6 %	Las cinco transformaciones T1–T5 implementadas, ejecutadas de forma independiente, con salidas persistidas en <i>data/pandas/</i> y código legible en <i>lstlisting</i> .	Las cinco transformaciones implementadas; alguna sin salida persistida o con código poco documentado.	Tres o cuatro transformaciones implementadas.	Menos de tres transformaciones o código que no ejecuta.
1.3 Implementación distribuida con PySpark	8 %	Las cinco transformaciones equivalentes en <i>DataFrames</i> de PySpark, con acción de materialización explícita, notebook ejecutado con salidas visibles y captura de la <i>Spark UI</i> con DAG y <i>stages</i> de T3.	Las cinco transformaciones implementadas y ejecutadas; falta la captura de la <i>Spark UI</i> o la materialización explícita.	Tres o cuatro transformaciones, o notebook con celdas sin salida.	Implementación mínima o notebook sin evidencia de ejecución.
1.4 Equivalencia de resultados y documentación de la configuración	4 %	Equivalencia pandas/PySpark verificada por cardinalidad y agregados de control para las cinco transformaciones, con tabla comparativa; versiones de PySpark, Python y plataforma declaradas.	Equivalencia verificada para la mayoría de transformaciones; versiones declaradas.	Verificación superficial o solo para una transformación.	Sin verificación de equivalencia.
D2 – PROTOCOLO EXPERIMENTAL Y ANÁLISIS CUANTITATIVO (25 %)					

continúa en la página siguiente

Criterio	Peso	4 – Sobresaliente	3 – Satisfactorio	2 – En desarrollo	1 – Insuficiente
2.1 Protocolo de medición	7 %	Cinco repeticiones por transformación con <code>perf_counter()</code> , mediana reportada, ejecución de calentamiento descartada y declarada, y medición de T3 con 1, 2 y 4 <i>executors</i> ; tiempos crudos publicados en <code>resultados/tiempos_crudos.csv</code> .	Cinco repeticiones y mediana; escalado de T3 presente; falta la declaración del calentamiento o los tiempos crudos.	Menos de cinco repeticiones o escalado incompleto (solo dos configuraciones).	Medición única, sin repeticiones ni escalado.
2.2 Cálculo de <i>speedup</i>, fracción serial y límite de Amdahl	8 %	<i>Speedup</i> calculado para las cinco transformaciones; fracción serial observada obtenida con la forma inversa y sustitución numérica paso a paso; $S_{\text{máx}}$ para $N \rightarrow \infty$; distinción explícita entre fracción serial algorítmica y sobrecarga del motor.	Cálculos correctos y completos con trabajo matemático presente; sin la distinción conceptual sobre la sobrecarga.	Solo se reportan resultados sin desarrollo, o el cálculo de la fracción serial contiene errores.	Cálculo ausente o conceptualmente erróneo.
2.3 Figuras generadas con matplotlib	6 %	Las tres figuras exigidas a 300 DPI, generadas por código publicado, con ejes rotulados y unidades, <code>\caption</code> , <code>\label</code> , referencia cruzada y párrafo interpretativo propio de cada una.	Las tres figuras presentes y correctas; interpretación breve.	Dos figuras, o figuras sin interpretación, o resolución insuficiente.	Una figura o capturas de pantalla en lugar de gráficos generados.
2.4 Tabla de tiempos y discusión de la sobrecarga	4 %	Tabla <code>booktabs</code> con tiempos de pandas y PySpark, <i>speedup</i> e interpretación por transformación, con unidades en <code>siunitx</code> ; discusión razonada del umbral de volumen a partir del cual Spark resulta rentable en el dominio del PFC.	Tabla completa con discusión breve del umbral.	Tabla incompleta o discusión meramente descriptiva.	Tabla sin análisis o con datos inconsistentes con el notebook.

D3 – FUNDAMENTO TEÓRICO Y PREGUNTAS DE ANÁLISIS (18 %)

continúa en la página siguiente

Criterio	Peso	4 – Sobresaliente	3 – Satisfactorio	2 – En desarrollo	1 – Insuficiente
3.1 Cobertura de los cuatro subtemas de la Unidad 4	7 %	Los cuatro subtemas desarrollados con más de 300 palabras cada uno; cada afirmación no trivial respaldada por al menos dos referencias con DOI o ISBN; conexión explícita con el dominio del PFC.	Los cuatro subtemas presentes con una o dos afirmaciones sin doble referencia.	Tres subtemas presentes, o varios con una sola referencia.	Cobertura fragmentaria o sin respaldo bibliográfico.
3.2 Formalización matemática de Amdahl y Gustafson	5 %	Derivación completa de Amdahl, formulación de Gustafson-Barsis, eficiencia y forma inversa de la fracción serial, todas en entornos numerados y referenciadas con <code>\eqref</code> ; curvas para $p = 0,5; 0,75; 0,9; 0,95$.	Ecuaciones presentes y numeradas; falta alguna de las curvas o la derivación es sintética.	Ecuaciones presentadas sin derivación o fuera de entornos matemáticos.	Ecuaciones ausentes o incorrectas.
3.3 Preguntas de análisis obligatorias	6 %	Las cuatro preguntas del Anexo A respondidas con más de 200 palabras cada una, aplicando los conceptos al PFC y citando referencias del <code>.bib</code> .	Las cuatro respondidas con extensión adecuada; alguna sin cita explícita.	Tres preguntas respondidas o extensión insuficiente.	Respuestas superficiales o sin fundamento.
D4 – CALIDAD ACADÉMICA DEL DOCUMENTO $\text{\LaTeX}$ (14 %)					
4.1 Estructura y compilación	5 %	Estructura de artículo técnico completa; más de 14 páginas de contenido; compila con <code>pdflatex</code> sin errores ni <i>overfull hbox</i> ; sin referencias sin resolver.	Estructura completa; compila con advertencias menores.	Estructura básica; compila tras correcciones del docente.	Estructura incompleta o compilación con errores.
4.2 Figuras, tablas, código y ecuaciones	5 %	Todas las figuras con <code>\caption</code> , <code>\label</code> y <code>\ref</code> ; tablas con <code>booktabs</code> ; código en <code>lstlisting</code> ; ecuaciones numeradas; unidades con <code>siunitx</code> .	Convenciones seguidas con uno o dos elementos sin etiqueta.	Convenciones parciales; capturas sin <code>\caption</code> .	Sin convenciones tipográficas correctas.
4.3 Referencias con biblatex IEEE	4 %	<code>biblatex</code> estilo IEEE; al menos 8 referencias, de ellas al menos 6 con DOI o ISBN verificable; todas citadas en contexto; ninguna de relleno.	Siete u ocho referencias, la mayoría con DOI; formato IEEE consistente.	Cinco o seis referencias con verificación parcial; inconsistencias de formato.	Menos de cinco referencias o formato distinto de IEEE en varias entradas.
D5 – REPOSITORIO, REPRODUCIBILIDAD Y COLABORACIÓN (10 %)					

continúa en la página siguiente

Criterio	Peso	4 – Sobresaliente	3 – Satisfactorio	2 – En desarrollo	1 – Insuficiente
5.1 Estructura del repositorio y URL	4 %	Repositorio público con la estructura del Listado 1 completa; README.md descriptivo con instrucciones exactas de compilación; LICENSE ; .gitignore ; URL corta en una sola línea.	Estructura correcta con carencias menores; URL en una línea.	Estructura parcial; carpetas ausentes.	Repositorio desordenado o sin instrucciones.
5.2 Colaboración Git verificable	3 %	Cada integrante con al menos tres <i>commits</i> significativos en fechas distintas; historia coherente; sin cargas masivas de último minuto.	Cada integrante con al menos dos <i>commits</i> ; historia razonable.	Colaboración desigual; algún integrante con un solo <i>commit</i> .	Colaboración concentrada en una o dos personas.
5.3 Reproducibilidad de extremo a extremo	3 %	El README.md permite reproducir todo el experimento en 15 minutos o menos desde la clonación hasta las figuras; comandos exactos; versiones fijadas; semillas declaradas.	Reproducible con ajustes menores.	Reproducible con esfuerzo significativo.	Instrucciones ausentes o inservibles.
D6 – REDACCIÓN CIENTÍFICA, ÉTICA E IA (8 %)					
6.1 Precisión terminológica y redacción	3 %	Terminología técnica precisa; sin errores gramaticales; tiempos verbales consistentes; estilo académico impersonal.	Terminología correcta con dos o tres imprecisiones menores.	Terminología inconsistente.	Errores gramaticales que dificultan la lectura.
6.2 Declaración de uso de IA generativa	2 %	Declaración explícita al final del documento con herramienta, propósito y secciones asistidas, conforme a los lineamientos de la asignatura.	Declaración presente pero incompleta.	Declaración genérica sin detalle.	Mención marginal o ambigua.
6.3 Conclusiones individuales	3 %	Cada integrante presenta una conclusión individual de más de 150 palabras con aprendizaje técnico específico y conexión con el PFC de referencia.	Conclusiones individuales presentes; alguna con menos de 150 palabras.	Conclusiones grupales sin individualización.	Conclusiones ausentes o genéricas.

12 Fórmula de cálculo

Para cada uno de los veinte criterios se aplica:

$$\text{Pts. obtenidos}_i = \text{Nivel}_i \times \frac{\text{Peso}_i (\%) }{4} \quad (6)$$

La *nota previa* del equipo, entendida como el valor del trabajo efectivamente realizado antes de aplicar penalizaciones y pisos, es

$$\text{Nota previa } (/100) = \sum_{i=1}^{20} \text{Pts. obtenidos}_i, \quad (7)$$

donde $\text{Nivel}_i \in \{0, 1, 2, 3, 4\}$ y $\sum_i \text{Peso}_i = 100$.

La calificación final se obtiene aplicando primero las penalizaciones de la sección 10.3 y, después, los pisos absolutos de la sección 10.2:

$$\text{Nota final } (/100) = \begin{cases} 0, & \text{si se activa cualquier piso P1–P4,} \\ \text{máx}(0, \text{Nota previa} - \text{Penalizaciones}), & \text{en caso contrario.} \end{cases} \quad (8)$$

Obligación de transparencia en la devolución

En toda retroalimentación se comunican al equipo ambos valores: la *nota previa* obtenida con (7) y la *nota final* resultante de (8), junto con la identificación del piso o de la penalización aplicada. El propósito es pedagógico: cuando un piso anula la calificación, el estudiante debe poder ver con exactitud cuánto trabajo válido se perdió por una omisión formal evitable.

13 Hoja de puntuación del evaluador

Criterio	Nivel (0–4)	Peso %	Pts.	Observación del evaluador
D1 – Entorno, datos e implementación (25 %)				
1.1 Entorno Spark y conjunto de datos real	_____	7	_____	
1.2 Implementación secuencial con pandas	_____	6	_____	
1.3 Implementación distribuida con PySpark	_____	8	_____	
1.4 Equivalencia y documentación de la configuración	_____	4	_____	
D2 – Protocolo experimental y análisis cuantitativo (25 %)				
2.1 Protocolo de medición	_____	7	_____	
2.2 Speedup, fracción serial y límite de Amdahl	_____	8	_____	
2.3 Figuras generadas con matplotlib	_____	6	_____	
2.4 Tabla de tiempos y discusión de la sobrecarga	_____	4	_____	
D3 – Fundamento teórico y preguntas (18 %)				
3.1 Cobertura de los cuatro subtemas	_____	7	_____	
3.2 Formalización de Amdahl y Gustafson	_____	5	_____	
3.3 Preguntas de análisis obligatorias	_____	6	_____	
D4 – Documento L^AT_EX (14 %)				
4.1 Estructura y compilación	_____	5	_____	
4.2 Figuras, tablas, código y ecuaciones	_____	5	_____	
4.3 Referencias con biblatex IEEE	_____	4	_____	
D5 – Repositorio, reproducibilidad y colaboración (10 %)				
5.1 Estructura del repositorio y URL	_____	4	_____	
5.2 Colaboración Git verificable	_____	3	_____	
5.3 Reproducibilidad de extremo a extremo	_____	3	_____	
D6 – Redacción científica, ética e IA (8 %)				
6.1 Precisión terminológica y redacción	_____	3	_____	
6.2 Declaración de uso de IA generativa	_____	2	_____	
6.3 Conclusiones individuales	_____	3	_____	
NOTA PREVIA (suma de puntos)		100	_____	
Penalizaciones aplicadas			_____	
Piso activado (P1–P4)			Sí / No	
NOTA FINAL			_____	

14 Retroalimentación estructurada

Fortalezas destacadas

Áreas de mejora prioritarias

Recomendaciones para la entrega final del PFC (Unidad 5)

Observaciones sobre integridad académica

15 Nota metodológica

Esta rúbrica se deriva de la consigna de GA-SUM-05 registrada en el cronograma maestro de la asignatura (Semana 14, Unidad 4) y de la guía institucional de práctica experimental correspondiente, cuyos diez apartados se conservan sin supresiones y se amplían con los criterios de verificación necesarios para una evaluación sumativa trazable (véase el Anexo B).

El diseño concentra el 50 % del peso en las dimensiones D1 y D2, es decir, en la evidencia experimental y en su análisis cuantitativo, porque el resultado de aprendizaje de la unidad se enuncia en términos de *implementar* y *evaluar rendimiento*, no de describir tecnologías. La dimensión D3 sostiene el 18 % para garantizar que la comprobación empírica se apoye en el modelo formal y no se degrade en un ejercicio de programación sin marco teórico. Las dimensiones D4 a D6 reproducen, con pesos ajustados, la estructura del instrumento GA-SUM-03 / PE-U3 de la Unidad 3, de modo que el estudiante encuentre el mismo contrato evaluativo a lo largo del período y pueda transferir los aprendizajes de forma acumulativa.

La escala de cinco niveles, la fórmula ponderada y la política de pisos mantienen coherencia con los demás instrumentos de la asignatura (TA-IND-01, TA-IND-02, FORM-IC-02, PE-U1 y PE-U3). La novedad respecto de PE-U3 es la exigencia de publicar los tiempos crudos y las semillas, un requisito de reproducibilidad que responde directamente a las debilidades detectadas en la evaluación de la práctica anterior, donde varios equipos reportaron mediciones que el código entregado no permitía reconstruir.

Anexo B — Trazabilidad con la guía institucional de práctica experimental

La tabla siguiente demuestra que ningún apartado de la guía institucional original ha sido suprimido, y precisa la ampliación introducida en cada caso.

Apartado de la guía institucional	Ubicación en este instrumento	Ampliación introducida
1. Datos generales	Sección 1	Se añaden código de actividad, semana de entrega, carácter sumativo y entregables.
2. Datos académicos: resultado de aprendizaje	Sección 2	Se distingue el resultado principal de la unidad del complementario de la asignatura.
2. Tema de la práctica	Sección 3	Se explicita la conexión con los cuatro subtemas teóricos y con el PFC de referencia.
3. Objetivo general y objetivos específicos	Sección 4	Se conservan literalmente; se añade la aclaración sobre los mínimos de la consigna breve.
4. Fundamento teórico (4.1–4.4)	Secciones 5.1–5.4	Se conservan los cuatro subtemas y sus referencias mínimas; se añaden la formalización obligatoria y la advertencia sobre la fracción serial observada.
5. Materiales, equipos, insumos y reactivos	Sección 6	Se conserva el listado íntegro; se añaden gestión bibliográfica y control de versiones.
6. Procedimientos (Pasos 1–5)	Sección 7	Se conservan los cinco pasos y sus notas de advertencia; se añaden pesos de rúbrica y evidencia de ejecución obligatoria.
7. Bibliografía	Bibliografía final	Se conservan las seis referencias originales y se amplían a dieciséis, todas verificadas con DOI o ISBN.
8. Anexos: preguntas de análisis	Anexo A (sección 9)	Se conservan las cuatro preguntas; se añade la exigencia de 200 palabras y cita del .bib.
9. Resultados de estudiantes	Secciones 13 y 14	Se sustituye el espacio en blanco por la hoja de puntuación y la retroalimentación estructurada.
10. Responsables	Firmas finales	Se conserva el bloque de firmas institucional.

Bibliografía de referencia

- [1] N. Ahmed, A. L. C. Barczak, T. Susnjak y M. A. Rashid, “A Comprehensive Performance Analysis of Apache Hadoop and Apache Spark for Large Scale Data Sets Using HiBench,” *Journal of Big Data*, vol. 7, n.º 1, pág. 110, 2020. DOI: 10.1186/s40537-020-00388-5.
- [2] G. M. Amdahl, “Validity of the Single Processor Approach to Achieving Large Scale Computing Capabilities,” en *Proceedings of the April 18–20, 1967, Spring Joint Computer Conference (AFIPS '67 (Spring))*, Atlantic City, NJ, USA: ACM, 1967, págs. 483-485. DOI: 10.1145/1465482.1465560.
- [3] M. Armbrust, R. S. Xin, C. Lian et al., “Spark SQL: Relational Data Processing in Spark,” en *Proceedings of the 2015 ACM SIGMOD International Conference on Management of Data (SIGMOD '15)*, Melbourne, VIC, Australia: ACM, 2015, págs. 1383-1394. DOI: 10.1145/2723372.2742797.
- [4] M.-M. Aseman-Manzar, S. Karimian-Aliabadi, R. Entezari-Maleki, B. Egger y A. Movaghar, “Cost-Aware Resource Recommendation for DAG-Based Big Data Workflows: An Apache Spark Case Study,” *IEEE Transactions on Services Computing*, vol. 16, n.º 3, págs. 1726-1737, 2023. DOI: 10.1109/TSC.2022.3203010.
- [5] B. Burns, *Designing Distributed Systems: Patterns and Paradigms for Scalable, Reliable Systems Using Kubernetes*, 2.ª ed. Sebastopol, CA, USA: O'Reilly Media, 2024, ISBN: 978-1-098-15635-0.
- [6] B. Chambers y M. Zaharia, *Spark: The Definitive Guide. Big Data Processing Made Simple*. Sebastopol, CA, USA: O'Reilly Media, 2018, ISBN: 978-1-4920-3251-9.

-
- [7] J. Dean y S. Ghemawat, “MapReduce: Simplified Data Processing on Large Clusters,” *Communications of the ACM*, vol. 51, n.º 1, págs. 107-113, 2008. DOI: 10.1145/1327452.1327492.
- [8] J. L. Gustafson, “Reevaluating Amdahl’s Law,” *Communications of the ACM*, vol. 31, n.º 5, págs. 532-533, 1988. DOI: 10.1145/42411.42415.
- [9] P. Mell y T. Grance, “The NIST Definition of Cloud Computing,” National Institute of Standards y Technology, Gaithersburg, MD, USA, Special Publication 800-145, 2011. DOI: 10.6028/NIST.SP.800-145.
- [10] T. White, *Hadoop: The Definitive Guide*, 4.^a ed. Sebastopol, CA, USA: O’Reilly Media, 2015, ISBN: 978-1-4919-0163-2.
- [11] M. Zaharia, M. Chowdhury, T. Das et al., “Resilient Distributed Datasets: A Fault-Tolerant Abstraction for In-Memory Cluster Computing,” en *Proceedings of the 9th USENIX Symposium on Networked Systems Design and Implementation (NSDI ’12)*, San Jose, CA, USA: USENIX Association, 2012, págs. 15-28.
- [12] M. Zaharia, R. S. Xin, P. Wendell et al., “Apache Spark: A Unified Engine for Big Data Processing,” *Communications of the ACM*, vol. 59, n.º 11, págs. 56-65, 2016. DOI: 10.1145/2934664.

GUERRERO ULLOA GLEISTON CICE-
RÓN

CI: 0913531752

DOCENTE RESPONSABLE

PONCE ORDOÑEZ JESSICA ALEXAN-
DRA

CI: 1205316456

COORDINADORA DE CARRERA

Gleiston C. Guerrero-Ulloa, M.Sc. – Docente responsable de Aplicaciones Distribuidas (ISR-701)
Facultad de Ciencias de la Computación – Universidad Técnica Estatal de Quevedo – Período académico 2026–2027
PPA