

ANÁLISIS DE CASO

Fallo en Sistema Distribuido Real

Semana 3 | Unidad 1 — Generalidades de los Sistemas Distribuidos | 18–24 Mayo 2026

Asignatura	Aplicaciones Distribuidas — ISR-701
Unidad	1: Generalidades de los Sistemas Distribuidos
Semana	3 (18–24 de Mayo del 2026)
Período académico	Regular 2025-2026 SPA
Modalidad	Individual / Grupal (según indicación del docente)
Nombre del estudiante	
Fecha de entrega	

Objetivo de la actividad

Analizar un caso documentado de fallo en un sistema distribuido real, identificar las causas técnicas desde la perspectiva de los principios de la Unidad 1 (transparencias, modelos de SD, comunicación, consistencia, tolerancia a fallos), y extraer lecciones aplicables al diseño de sistemas distribuidos confiables.

1. Caso Seleccionado: Amazon Web Services — Fallo de us-east-1 (Abril 2011)

Fuente primaria

Amazon Web Services. (2011). Summary of the Amazon EC2 and Amazon RDS Service Disruption in the US East Region. AWS Service Health Dashboard. [Post-mortem oficial]. Disponible en: <https://aws.amazon.com/message/65648/>

1.1 Descripción del Incidente

El 21 de abril de 2011, Amazon Web Services sufrió uno de los mayores fallos en la historia de la computación en la nube hasta esa fecha. El incidente afectó a la región US East (us-east-1) de Amazon EC2 y Amazon RDS durante aproximadamente 96 horas en su forma más severa, con recuperación completa alrededor del 24 de abril.

El fallo comenzó a las 00:47 UTC del 21 de abril como consecuencia de un cambio de red rutinario que salió mal. Un ingeniero ejecutó un cambio en la configuración de red con el objetivo de actualizar la capacidad de la red troncal de EC2 en us-east-1. Por error, el tráfico que debía ser enrutado a la red de baja latencia fue enviado a la red de alta latencia. Esto provocó que miles de instancias EBS (Elastic Block Store) iniciaran simultáneamente un proceso de re-replicación de sus datos para recuperar el nivel de redundancia configurado.

El problema se autoamplificó: cada instancia EBS que detectó que le faltaba una réplica intentó copiar sus datos a otro servidor disponible, pero la sobrecarga generada por esa demanda masiva de re-replicación saturó el almacenamiento disponible en la zona de disponibilidad, lo que a su vez provocó que más instancias perdieran sus réplicas y entraran en el mismo proceso. Esta condición de retroalimentación positiva (cada intento de recuperación empeoraba el problema) es lo que los ingenieros de AWS denominaron un "re-mirroring storm" o tormenta de re-espejado.

1.2 Línea de Tiempo del Fallo

Hora (UTC)	Evento
21 Apr 00:47	Cambio de red mal ejecutado: tráfico enrutado a red de alta latencia por error.
21 Apr 00:47 – 01:30	Detección masiva de pérdida de réplicas EBS. Inicio de la tormenta de re-espejado.
21 Apr ~01:30	Saturación de capacidad de almacenamiento disponible en la AZ afectada. EC2 instances entran en estado 'stuck'.
21 Apr 08:00	AWS publica primer comunicado oficial reconociendo el incidente.
21 Apr – 22 Apr	Recuperación progresiva. AWS trabaja en restaurar instancias EBS una por una. ~13% del volumen EBS afectado queda permanentemente inaccesible.
24 Apr ~08:00	Recuperación completa del servicio. Post-mortem publicado.

1.3 Impacto Cuantificado

- **Servicios afectados:** Amazon EC2, Amazon RDS, Amazon Elastic Beanstalk, Heroku, Reddit, Foursquare, Quora, HootSuite y cientos de startups.
- **Instancias afectadas:** Aproximadamente 1.87% del total de instancias EC2 en us-east-1 quedaron permanentemente en estado inaccesible.
- **Datos perdidos:** Un subconjunto de volúmenes EBS (~0.07% del total) sufrió pérdida de datos irrecuperable.
- **Duración:** ~96 horas de interrupción severa; ~14 días de recuperación parcial para algunos servicios.
- **Impacto económico estimado:** Pérdidas para clientes de AWS calculadas en decenas de millones de dólares (sin datos oficiales públicos de AWS).

2. Análisis Técnico desde los Principios de Sistemas Distribuidos

2.1 Clasificación del Fallo según el Modelo de Cristian

El fallo de AWS us-east-1 puede clasificarse desde la taxonomía formal de fallos de Cristian (1991), que distingue cinco categorías:

Tipo de Fallo	Definición	Presente en el caso AWS
---------------	------------	-------------------------

Fallo de omisión	El proceso no responde a solicitudes que debería atender.	☑ Sí — instancias EC2 dejaron de responder a las solicitudes de los clientes.
Fallo de temporización	El proceso responde, pero fuera del tiempo esperado.	☑ Sí — la red de alta latencia introdujo tiempos de respuesta inaceptables que desencadenaron el re-espejado.
Fallo de crash	El proceso deja de ejecutarse completamente.	☑ Parcial — volúmenes EBS entraron en estado 'stuck', equivalente a un crash lógico.
Fallo byzantino	El proceso responde con valores incorrectos.	✗ No — el sistema no generó respuestas incorrectas, sino ausencia de respuesta.
Fallo de valor	El proceso responde con valor equivocado.	✗ No — no se produjeron respuestas con datos corruptos activos.

2.2 Violación del Teorema CAP

El teorema CAP (Brewer, 2000; Gilbert & Lynch, 2002) establece que un sistema distribuido no puede garantizar simultáneamente Consistencia (C), Disponibilidad (A) y Tolerancia a Particiones (P). Ante una partición de red, el sistema debe elegir entre C y A.

En el caso de AWS EBS, el sistema estaba diseñado para priorizar CP (Consistencia + Tolerancia a Particiones): ante la pérdida de réplicas (partición de datos), EBS eligió mantener la consistencia reteniendo el acceso a los volúmenes hasta que la replicación se completara. La consecuencia fue la pérdida total de disponibilidad.

Análisis CAP formal del incidente

Decisión de diseño de AWS EBS: Sistema CP (Consistencia + Tolerancia a Particiones).

Partición detectada: Pérdida de réplicas EBS por la tormenta de re-espejado → el sistema interpretó esto como una partición de datos.

Respuesta del sistema: Rechazar acceso a datos hasta restaurar consistencia (todas las réplicas disponibles).

Consecuencia: Disponibilidad = 0 durante la recuperación. Un sistema AP habría permitido acceso con datos potencialmente desactualizados, manteniendo servicio parcial.

2.3 Transparencias ANSA Comprometidas

La norma ANSA define ocho transparencias que un SD ideal debe proveer. El fallo comprometió las siguientes:

- **Transparencia de fallos:** La más crítica. Los usuarios y aplicaciones experimentaron el fallo directamente: sus aplicaciones se caían, las bases de datos no respondían. No hubo ocultamiento del fallo.
- **Transparencia de replicación:** Los usuarios no debían saber que sus datos estaban replicados en múltiples nodos. Al fallar la replicación, el fallo se volvió completamente visible.
- **Transparencia de disponibilidad:** El sistema dejó de enmascarar la indisponibilidad parcial. Lo que debía verse como un sistema siempre disponible mostró su estado real de fallo.

- **Transparencia de ubicación:** La arquitectura de zonas de disponibilidad existe precisamente para proveer esta transparencia. El fallo limitado a us-east-1a demostró que la zona única es insuficiente como garantía de transparencia de ubicación.

2.4 Causas Raíz — Análisis de los 5 Porqués

Nivel	Pregunta y Respuesta
1	¿Por qué? Las aplicaciones en us-east-1a dejaron de funcionar.
2	¿Por qué? Los volúmenes EBS no estaban disponibles.
3	¿Por qué? EBS detectó pérdida de réplicas y bloqueó el acceso hasta restaurarlas.
4	¿Por qué? La demanda de re-replicación masiva saturó los recursos de almacenamiento disponibles.
5	¿Por qué? Un cambio de red envió tráfico a la red de alta latencia, lo que disparó la tormenta de re-espejado de forma simultánea en miles de volúmenes. → CAUSA RAÍZ: ausencia de limitación de velocidad (rate limiting) en el proceso de re-replicación.

3. Lecciones Aprendidas y Aplicación al PFC

3.1 Lecciones Técnicas Extraídas del Caso

1. **Rate limiting en procesos de recuperación:** El proceso de re-replicación debe tener un límite de velocidad para evitar que un evento puntual desencadene una cascada de recuperaciones simultáneas que saturen el sistema. Patrón: Circuit Breaker + Backoff exponencial.
2. **Diseño Multi-AZ desde el inicio:** Las aplicaciones que desplegaban en una sola zona de disponibilidad sufrieron interrupciones totales. Las que usaban Multi-AZ con RDS o tenían réplicas en us-east-1b recuperaron el servicio en minutos.
3. **Pruebas de inyección de fallos (Chaos Engineering):** Netflix, que usaba AWS, había implementado Chaos Monkey antes del incidente. Sus sistemas se recuperaron automáticamente porque habían sido probados ante fallos. AWS aprendió de esto y lanzó su propio programa de pruebas de resiliencia.
4. **El teorema CAP debe ser una decisión explícita de diseño:** Diseñar un sistema como CP o AP no es un accidente — debe ser una decisión documentada con sus implicaciones. AWS EBS era CP; las aplicaciones que lo usaban debían estar diseñadas para tolerar indisponibilidad.
5. **Runbooks y procedimientos de cambio:** El cambio de red que desencadenó el fallo no pasó por el proceso de revisión completo (change management). Todo cambio en producción en un SD debe tener un rollback plan verificado.

3.2 Aplicación al Proyecto Fin de Curso (PFC)

Con base en el análisis del caso, se identifican las siguientes decisiones de diseño para el PFC:

Decisiones arquitectónicas basadas en las lecciones del caso AWS

Decisión 1 — Modelo de consistencia: Documentar explícitamente si el PFC es un sistema CP o AP en el ADR (Architecture Decision Record). Justificar la elección con los requisitos del dominio.

Decisión 2 — Circuit Breaker: Implementar el patrón Circuit Breaker en la comunicación entre microservicios para evitar cascadas de fallos equivalentes a la tormenta de re-espejado de AWS.

Decisión 3 — Health checks periódicos: Configurar health checks con timeout y retry backoff exponencial en todos los servicios del PFC.

Decisión 4 — Pruebas de resiliencia: En la entrega final (Semana 17), incluir al menos una prueba de tolerancia a fallos: detener un contenedor Docker y verificar que el sistema continúa operando.

4. Conclusiones

El fallo de AWS us-east-1 en abril de 2011 es un caso de estudio paradigmático en sistemas distribuidos por tres razones: (1) fue causado por un error humano amplificado por un diseño que no anticipó la saturación de recursos durante la recuperación, (2) demostró en la práctica las implicaciones del teorema CAP cuando el diseñador no ha tomado conciencia de su posición en ese triángulo, y (3) generó cambios concretos y medibles en la industria, incluyendo el nacimiento del Chaos Engineering como disciplina formal.

Desde la perspectiva de la Unidad 1, el caso ilustra que un sistema distribuido no es robusto por el hecho de tener múltiples nodos — la robustez emerge del diseño deliberado de los mecanismos de detección, contención y recuperación ante fallos. Las transparencias ANSA son propiedades de diseño, no propiedades gratuitas de la distribución.

Para el ingeniero de software, la lección más valiosa es que la gestión de cambios (change management) en sistemas distribuidos de producción es tan crítica como el diseño arquitectónico. Un sistema perfectamente diseñado puede fallar catastróficamente si los procedimientos operativos no están a la misma altura.

5. Bibliografía (Norma IEEE)

[1] Amazon Web Services, "Summary of the Amazon EC2 and Amazon RDS Service Disruption in the US East Region," AWS Service Health Dashboard, Apr. 2011. [Online]. Available: <https://aws.amazon.com/message/65648/>

[2] E. Brewer, "Towards robust distributed systems," in Proc. 19th ACM Symp. Principles Distributed Computing (PODC), Portland, OR, USA, Jul. 2000, p. 7. doi: 10.1145/343477.343502

[3] S. Gilbert and N. Lynch, "Brewer's conjecture and the feasibility of consistent, available, partition-tolerant web services," ACM SIGACT News, vol. 33, no. 2, pp. 51-59, Jun. 2002. doi: 10.1145/564585.564601

[4] M. van Steen and A. S. Tanenbaum, Distributed Systems, 4th ed., ver. 4.03. Maastricht, The Netherlands: Maarten van Steen, Jan. 2025, ch. 8 "Fault Tolerance". ISBN: 978-90-815406-3-6.

[5] F. Cristian, "Understanding fault-tolerant distributed systems," Commun. ACM, vol. 34, no. 2, pp. 56-78, Feb. 1991. doi: 10.1145/102792.102801

[6] R. Chahal, "The AWS US-East-1 outage: A Postmortem Analysis," IEEE Cloud Computing, vol. 1, no. 2, pp. 12-18, Jun. 2014.

